

A thick black L-shaped frame is positioned on the left and bottom edges of the slide, framing the central text.

MINI AUTOML SYSTEM

Projekt 2 – Automatyczne Uczenie Maszynowe

Ada Wojterska, Katarzyna Skoczylas, Miłosz Zieliński

Cel projektu

- Stworzenie prostego systemu AutoML, umożliwiającego wykonywanie zadania klasyfikacji binarnej na dowolnym zbiorze danych tabelarycznych
- Skonstruowanie i wykorzystanie autorskiego portfolio modeli

Wykorzystane algorytmy

Logistic Regression

LightGBM

XGBoost

Decision Tree

Random Forest

Budowa portfolio modeli

- Cel: Wybór 50 modeli
- 250 konfiguracji hiperparametrów – 50 dla każdej rodziny algorytmów
- Testy na 6 różnorodnych zbiorach OpenML
- Metryka: Balanced Accuracy i Total Balanced Accuracy
- Wymóg zróżnicowania portfolio

Ostateczny skład portfolio

Logistic Regression - 25

XGBoost - 12

LightGBM - 7

Decision Tree - 3

Random Forest - 3

Przygotowanie danych - preprocessing

- Braki danych – mediana (zmienne numeryczne) i moda (zmienne katagoryczne)
- One-Hot encoding
- Standaryzacja cech numerycznych

Strategia wyboru modeli

- Testowanie wszystkich 50 zestawów konfiguracji
- Do 10000 losowych instancji
- 3-fold cross-validation
- Metryka: Balanced Accuracy
- Wybór Top-5 z co najmniej 3 różnych grup modeli dla zróżnicowania

Ensembling

- Soft-voting (Top-3)
- Soft-voting (Top-5)
- Stacking with final estimator Logistic Regression (Top-3)
- Stacking with final estimator Logistic Regression with passthrough (Top-3)
- Stacking with final estimator Random Forest Classifier (Top-3)

Ocena końcowa

- Wybierany jest najlepszy pojedynczy model lub najlepszy ensembling (5-fold cross-validation)
- Cały zbiór danych jest trenowany na zwycięzcy
- To jest ostateczny model

Zarządzanie czasem

- Dynamiczna kontrola czasu
- Wstępny screening na max 10000 losowych obserwacjach
- Możliwe przerwanie wstępnego screeningu
- Warunkowy ensembling (dostępne co najmniej 30% całego czasu)

Czas działania

Dataset	Liczba obserwacji	Czas wykonywania	Wybrany model
Prima Indians	768	0:34 min	LogisticRegression_16
Bank Marketing	11 162	2:40 min	Stacking_RF
Provided Dataset	3 481	1:20 min	Stacking_Top3_Passthrough
Airline Passenger Satisfaction	129 980	4:30 min	Voting_Top5

Porównanie wyników

Balanced accuracy

Dataset	LightAutoML	MLJAR	MiniAutoML
Prima Indians	0,7272	0,7644	0,7361
Bank Marketing	0,8347	0,8568	0,8662
Provided Dataset	0,5390	0,5266	0,5537

Podsumowanie

MiniAutoML to system do klasyfikacji binarnej, który jest:

- Efektywny
- Szybki
- Wykorzystuje portfolio 50 modeli
- Wybiera modele pojedyncze lub ensemblingi (stacking i voting)